

# Linear Algebra for Statistics

## Chapter 6

Instructor: Seokho Lee (이석호)

Hankuk University of Foreign Studies

## Chapter 6 행렬의 응용

### 6.1 마르코프 연쇄와 전이행렬

확률과정(stochastic process)이란 서로 다른  $n$  개(혹은 무한개)의 상태(state)가 있을 때, 한 상태에서 다른 상태로 옮겨지는 확률적 과정을 의미한다.

확률과정에서 한 상태에서 다른 상태로 이동(전이, transition)할 확률을 일단계 전이확률(one-step transition probability)라하며, 이를  $n \times n$  행렬로 표현한 것을 전이행렬(transition matrix)이라 한다.

$j$  번째 상태에서  $i$  번째 상태로 전이되는 확률을

$$p_{ij} = \Pr(X_t = i | X_{t-1} = j)$$

라고 하면, 전이행렬은 아래와 같다.

$$P = \begin{pmatrix} p_{11} & p_{12} & \cdots & p_{1n} \\ p_{21} & p_{22} & \cdots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{n1} & p_{n2} & \cdots & p_{nn} \end{pmatrix}. \quad (6.1)$$

여기서, 열(column)은 ‘출발’을, 행(row)은 ‘도착’을 나타내며, 행렬의  $(i, j)$  원소  $p_{ij}$  는  $j$  상태에서 출발하여  $i$  상태로 전이될 확률을 나타낸다.

## Definition

행렬  $A$  가 전이행렬이 되기 위해서 아래의 조건을 만족하여야 한다.

- ①  $A$  는  $n \times n$  정방행렬이어야 한다.
- ②  $A$  의 모든 원소는  $0 \leq a_{ij} \leq 1$  이어야 한다.
- ③  $A$  의 모든 열에 대하여 열방향 원소의 합은 항상 1이다. 즉,  $\sum_{i=1}^n p_{ij} = 1$ ,  
 $\forall j = 1, 2, \dots, n$ .

## Example

예를 들어 다음의 행렬은 전이행렬의 조건을 만족시킨다.

$$P = \begin{pmatrix} 0.9 & 0.15 \\ 0.1 & 0.85 \end{pmatrix} \quad (6.2)$$

## Definition

어떤 상태로 이동하는 확률이 바로 이전 시점의 상태가 어떤 것인지에 영향을 받는 경우, 이를 마르코프 연쇄(Markov Chain)라고 하며, 이 연쇄를 설명하는 확률행렬을 전이행렬 (transition matrix)이라 한다.

## Example

다음의 전이행렬

$$P = \begin{pmatrix} 0.9 & 0.15 \\ 0.1 & 0.85 \end{pmatrix}$$

이 마르코프 연쇄를 설명한다고 하자. 현재 시점에서  $\mathbf{x}_t = (20, 70)^T$  이라고 한다면 다음 시점에서의 값을  $\mathbf{x}_{t+1}$  라고 하면 마르코프 연쇄에 의해

$$\mathbf{x}_{t+1} = P\mathbf{x}_t \quad (6.3)$$

$$= \begin{pmatrix} 0.9 & 0.15 \\ 0.1 & 0.85 \end{pmatrix} \begin{pmatrix} 20 \\ 70 \end{pmatrix} \quad (6.4)$$

$$= \begin{pmatrix} 28.5 \\ 61.5 \end{pmatrix} \quad (6.5)$$

## Example (continue)

이러한 추세로 그 다음 시점의 값  $\mathbf{x}_{t+2}$ 를 예측하면 마르코프 연쇄에 의해

$$\mathbf{x}_{t+2} = PP\mathbf{x}_t = P\mathbf{x}_{t+1} \quad (6.6)$$

$$= \begin{pmatrix} 0.9 & 0.15 \\ 0.1 & 0.85 \end{pmatrix}^2 \begin{pmatrix} 20 \\ 70 \end{pmatrix} = \begin{pmatrix} 0.9 & 0.15 \\ 0.1 & 0.85 \end{pmatrix} \begin{pmatrix} 28.5 \\ 61.5 \end{pmatrix} \quad (6.7)$$

$$= \begin{pmatrix} 34.9 \\ 55.1 \end{pmatrix} \quad (6.8)$$

가 된다.

## Example

택시들이 도시1, 도시2, 도시3 을 돌아다니며 운행하고 있다. 각 도시에서 손님을 태운다고 가정했을 때, 택시에 탄 손님이 각 도시를 목적지로 할 확률은 그림(Figure 6.1)과 같다. 각 도시에서 다른 도시에 이르는 확률을 전이행렬로 표시하라.




Figure 6.1: 택시 운전사가 도시 사이를 운행하면서 각 도시방향의 손님을 태울 확률

## Example (continue)

(풀이) 전이행렬은 다음과 같다.

$$P = \begin{pmatrix} 0.0 & 0.7 & 0.2 \\ 0.2 & 0.2 & 0.3 \\ 0.8 & 0.1 & 0.5 \end{pmatrix} \quad (6.9)$$

## Example

택시를 기다리는 사람의 수가 (도시1, 도시2, 도시3) = (10, 20, 30)이라고 할 때, 모든 사람이 택시를 타고 난 후 다음 도시에서 택시를 기다린다고 가정할 때, 두번째 택시를 기다리는 사람의 수는 얼마로 예상하는가?

(풀이)  $\mathbf{x} = (10, 20, 30)^T$  이라 하면,

$$P\mathbf{x} = \begin{pmatrix} 0.0 & 0.7 & 0.2 \\ 0.2 & 0.2 & 0.3 \\ 0.8 & 0.1 & 0.5 \end{pmatrix} \begin{pmatrix} 10 \\ 20 \\ 30 \end{pmatrix} = \begin{pmatrix} 20 \\ 15 \\ 25 \end{pmatrix}$$



## 6.2 선형함수와 선형변환

### Definition

함수  $f(x)$  가 아래 조건을 만족할 때

- ❶ 가법성(additivity) :  $f(x_1 + x_2) = f(x_1) + f(x_2)$
- ❷ 동질성(homogeneity) :  $f(ax) = af(x)$ ,  $a$  는 상수

이러한  $f(x)$  를 선형함수(linear function)라고 한다.

**Remark** 위의 조건 하에서 다음을 만족한다

$$f(a_1x_1 + a_2x_2) = a_1f(x_1) + a_2f(x_2). \quad (6.10)$$

## Example

함수  $f(x)$  가 선형함수인지 아닌지 판단하라.

(1)  $f(x) = 2x$

(2)  $f(x) = x^2$

(3)  $f(x) = \ln x$

(4)  $f(x) = 1 + x$

(풀이)  $f(x) = 2x$  는

$$f(a_1x_1 + a_2x_2) = 2(a_1x_1 + a_2x_2) = a_1(2x_1) + a_2(2x_2) = a_1f(x_1) + a_2f(x_2)$$

이므로 선형함수이다. 다른 함수들은 선형함수가 아님을 손쉽게 보일 수 있다. (4)의 경우, 직선함수이나 선형함수가 아님에 유의할 것.

## Definition

두 벡터  $\mathbf{x} \in \mathbb{R}^n$ ,  $\mathbf{y} \in \mathbb{R}^m$  와 행렬  $A_{m \times n}$  에 대하여, 함수  $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$  가

$$\mathbf{y} = f(\mathbf{x}) = A\mathbf{x} \quad (6.11)$$

라고 할 때,  $f$ 를 선형변환이라 한다.

## Proposition (6.1)

선형변환  $\mathbf{y} = A\mathbf{x}$  는 선형함수임을 보여라.

Proof.

$$f(a_1\mathbf{x}_1 + a_2\mathbf{x}_2) = A(a_1\mathbf{x}_1 + a_2\mathbf{x}_2) \quad (6.12)$$

$$= a_1A\mathbf{x}_1 + a_2A\mathbf{x}_2 \quad (6.13)$$

$$= a_1f(\mathbf{x}_1) + a_2f(\mathbf{x}_2) \quad (6.14)$$

이므로 선형함수이다. □

## 6.3 선형변환의 종류

### 6.3.1 회전변환

회전변환(rotation)은 공간상의 점들을 반시계방향(counter-clockwise)으로  $\theta$  만큼 회전시킨 변환을 의미한다.




Figure 6.2: 회전변환에 의해 변환된 벡터

이차원공간 상에서 점들을  $\theta$  만큼 반시계방향으로 회전하는 변환에 대응하는 선형변환을

$$\mathbf{y} = A\mathbf{x} \quad \text{with} \quad A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

라고 하자.

Figure 6.2의 왼쪽 그림에 의하면, 기본벡터  $\mathbf{e}_1 = (1, 0)^T$  을 반시계방향으로  $\theta$  만큼 회전하여 얻은 벡터는  $(\cos \theta, \sin \theta)$  이므로 다음이 성립한다.

$$\begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix} = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} a \\ c \end{pmatrix}. \quad (6.15)$$

즉,

$$a = \cos \theta, \quad c = \sin \theta$$

이다.

Figure 6.2의 오른쪽 그림에 의하면, 기본벡터  $\mathbf{e}_2 = (0, 1)^T$  을 반시계방향으로  $\theta$  만큼 회전하여 얻은 벡터는  $(-\sin \theta, \cos \theta)$  이므로 다음이 성립한다.

$$\begin{pmatrix} -\sin \theta \\ \cos \theta \end{pmatrix} = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} b \\ d \end{pmatrix}. \quad (6.16)$$

즉,

$$b = -\sin \theta, \quad d = \cos \theta$$

이다.

따라서,  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^2$ 에서,  $\mathbf{x} = (x_1, x_2)^T$  를 반시계방향으로  $\theta$  만큼 회전시켜 얻은  $\mathbf{y} = (y_1, y_2)^T$  는 아래와 같다.

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = A\mathbf{x}. \quad (6.17)$$




Figure 6.3: 회전변환에 의해 변환된 이미지

## Example

반시계방향으로 90도 회전시키는 선형변환을 이루는 행렬이 아래와 같음을 보여라.

$$A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}. \quad (6.18)$$



### 6.3.2 길이변환

다음 선형변환은 수평방향과 수직방향으로  $k$  배 시켜주는 변환이다.

$$\begin{aligned}\mathbf{y} &= A\mathbf{x} \\ \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} &= \begin{pmatrix} k & 0 \\ 0 & k \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}.\end{aligned}\tag{6.19}$$




Figure 6.4: 길이변환에 의해 크기가 2배로 확대된 이미지

### 6.3.3 내분점의 선형변환

#### Definition

두 벡터  $\mathbf{a}, \mathbf{b}$  를  $m : n$  으로 내분하는 벡터  $\mathbf{c}$  는

$$\mathbf{c} = \frac{n\mathbf{a} + m\mathbf{b}}{m + n} \quad (6.20)$$

로 구해지며, 그 모습은 Figure 6.5와 같다.




Figure 6.5: 벡터  $\mathbf{a}, \mathbf{b}$  를  $m : n$  으로 내분하는 벡터  $\mathbf{c}$

## Theorem (정리 6.2)

두 벡터  $\mathbf{a}, \mathbf{b}$  가 선형변환  $\mathbf{y} = A\mathbf{x}$  에 의해  $\mathbf{a}' = A\mathbf{a}$ ,  $\mathbf{b}' = A\mathbf{b}$  로 변환되었으면,  $\mathbf{a}, \mathbf{b}$  를  $m : n$  으로 내분하는  $\mathbf{c}$  에 대해서도

$$\mathbf{c}' = A\mathbf{c} = \frac{n\mathbf{a}' + m\mathbf{b}'}{m + n} \quad (6.21)$$

이 성립한다.

Proof.

$$A\mathbf{c} = A\left(\frac{n\mathbf{a} + m\mathbf{b}}{m + n}\right) = \left(\frac{n}{m + n}\right)A\mathbf{a} + \left(\frac{m}{m + n}\right)A\mathbf{b} = \frac{n\mathbf{a}' + m\mathbf{b}'}{m + n}$$

□

### 6.3.4 직교행렬과 직교변환

#### Definition

정방행렬  $A_{n \times n}$  이

$$A^T A = A A^T = I_n \quad (6.22)$$

을 만족하면  $A$  는 직교행렬(orthogonal matrix)이라고 한다.

#### Proposition (6.3)

$A$  가 직교행렬이면  $A^{-1} = A^T$  이다.

#### Example

직교행렬의 예:

$$A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}, \quad B = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}.$$

## Theorem (정리 6.4)

정방행렬  $A_{n \times n}$ 이 직교행렬이 되기 위한 필요충분조건은 아래와 같다.

$$(1) \mathbf{a}_i^T \mathbf{a}_j = \delta_{ij}, \quad i, j = 1, 2, \dots, n$$

$$(2) \tilde{\mathbf{a}}_i^T \tilde{\mathbf{a}}_j = \delta_{ij}, \quad i, j = 1, 2, \dots, n.$$

여기서  $\delta_{ij}$ 의 값은  $i = j$  이면 1,  $i \neq j$  이면 0 이다.

## Proof.

$A = (\tilde{\mathbf{a}}_1, \tilde{\mathbf{a}}_2, \dots, \tilde{\mathbf{a}}_n)$  이라 표현하면,

$$A^T A = \begin{pmatrix} \tilde{\mathbf{a}}_1^T \\ \tilde{\mathbf{a}}_2^T \\ \vdots \\ \tilde{\mathbf{a}}_n^T \end{pmatrix} (\tilde{\mathbf{a}}_1, \tilde{\mathbf{a}}_2, \dots, \tilde{\mathbf{a}}_n) = \begin{pmatrix} \tilde{\mathbf{a}}_1^T \tilde{\mathbf{a}}_1 & \tilde{\mathbf{a}}_1^T \tilde{\mathbf{a}}_2 & \cdots & \tilde{\mathbf{a}}_1^T \tilde{\mathbf{a}}_n \\ \tilde{\mathbf{a}}_2^T \tilde{\mathbf{a}}_1 & \tilde{\mathbf{a}}_2^T \tilde{\mathbf{a}}_2 & \cdots & \tilde{\mathbf{a}}_2^T \tilde{\mathbf{a}}_n \\ \vdots & \vdots & \ddots & \vdots \\ \tilde{\mathbf{a}}_n^T \tilde{\mathbf{a}}_1 & \tilde{\mathbf{a}}_n^T \tilde{\mathbf{a}}_2 & \cdots & \tilde{\mathbf{a}}_n^T \tilde{\mathbf{a}}_n \end{pmatrix}. \quad (6.23)$$

Proof (continue).

$A$  가 직교행렬이면  $A^T A = I_n$  이므로

$$\begin{pmatrix} \tilde{\mathbf{a}}_1^T \tilde{\mathbf{a}}_1 & \tilde{\mathbf{a}}_1^T \tilde{\mathbf{a}}_2 & \cdots & \tilde{\mathbf{a}}_1^T \tilde{\mathbf{a}}_n \\ \tilde{\mathbf{a}}_2^T \tilde{\mathbf{a}}_1 & \tilde{\mathbf{a}}_2^T \tilde{\mathbf{a}}_2 & \cdots & \tilde{\mathbf{a}}_2^T \tilde{\mathbf{a}}_n \\ \vdots & \vdots & \ddots & \vdots \\ \tilde{\mathbf{a}}_n^T \tilde{\mathbf{a}}_1 & \tilde{\mathbf{a}}_n^T \tilde{\mathbf{a}}_2 & \cdots & \tilde{\mathbf{a}}_n^T \tilde{\mathbf{a}}_n \end{pmatrix} = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}. \quad (6.24)$$

따라서  $\tilde{\mathbf{a}}_i^T \tilde{\mathbf{a}}_j = \delta_{ij}$  가 성립한다.

이제

$$A = \begin{pmatrix} \mathbf{a}_1^T \\ \mathbf{a}_2^T \\ \vdots \\ \mathbf{a}_n^T \end{pmatrix}$$

라 표현하자. 그러면

Proof (continue).

$$AA^T = \begin{pmatrix} \mathbf{a}_1^T \\ \mathbf{a}_2^T \\ \vdots \\ \mathbf{a}_n^T \end{pmatrix} (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n) = \begin{pmatrix} \mathbf{a}_1^T \mathbf{a}_1 & \mathbf{a}_1^T \mathbf{a}_2 & \cdots & \mathbf{a}_1^T \mathbf{a}_n \\ \mathbf{a}_2^T \mathbf{a}_1 & \mathbf{a}_2^T \mathbf{a}_2 & \cdots & \mathbf{a}_2^T \mathbf{a}_n \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_n^T \mathbf{a}_1 & \mathbf{a}_n^T \mathbf{a}_2 & \cdots & \mathbf{a}_n^T \mathbf{a}_n \end{pmatrix} \quad (6.25)$$

이고  $AA^T = I_n$  이어야 하므로,  $\mathbf{a}_i^T \mathbf{a}_j = \delta_{ij}$  가 성립한다. □

**Remark** 행렬  $A$  가 직교행렬이면 열벡터  $\tilde{\mathbf{a}}_i$  들은 직교정규벡터(orthonormal vector)이다.

**Remark** 행렬  $A$  가 직교행렬이면 행벡터  $\mathbf{a}_i$  들은 직교정규벡터(orthonormal vector)이다.



## Definition

선형변환  $\mathbf{y} = \mathbf{A}\mathbf{x}$  에서 변환행렬  $A_{n \times n}$ 이 직교행렬이면, 선형변환  $\mathbf{y} = \mathbf{A}\mathbf{x}$  를 직교변환 (orthogonal transformation)이라고 한다.

## Theorem (정리 6.5)

정방행렬  $A_{n \times n}$ 가 직교행렬이고,  $\mathbf{y} = \mathbf{A}\mathbf{x}$  를 만족할 때,

$$\|\mathbf{x}\| = \|\mathbf{y}\| \quad (6.26)$$

를 만족한다.

Proof.

$$\|\mathbf{y}\| = \|\mathbf{A}\mathbf{x}\| = \sqrt{(\mathbf{A}\mathbf{x})^T (\mathbf{A}\mathbf{x})} = \sqrt{\mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x}} = \sqrt{\mathbf{x}^T \mathbf{x}} = \|\mathbf{x}\|.$$

□

## Theorem (정리 6.6)

직교변환에 의해  $\mathbf{y}_1 = A\mathbf{x}_1$ ,  $\mathbf{y}_2 = A\mathbf{x}_2$  가 성립할 때,

$$\mathbf{y}_1^T \mathbf{y}_2 = \mathbf{x}_1^T \mathbf{x}_2 \quad (6.27)$$

가 성립한다. 즉 벡터의 내적값이 변환에 대해 불변이다.

Proof.

$$\mathbf{y}_1^T \mathbf{y}_2 = (A\mathbf{x}_1)^T (A\mathbf{x}_2) = \mathbf{x}_1^T A^T A \mathbf{x}_2 = \mathbf{x}_1^T \mathbf{x}_2.$$

□

## Example

회전변환  $\mathbf{y} = A\mathbf{x}$  는 직교변환이다.  $\mathbb{R}^2$  상의 회전변환에 대응하는 행렬

$$A = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} \text{ 는 } A^T A = A A^T = I_2 \text{ 이다.}$$

## 6.4 아핀변환(Affine Transformation)

직선함수  $f(x) = 2x$  가 선형함수 임에도 절편이 있는 직선함수

$$f(x) = 1 + 2x \quad (6.28)$$

는 선형함수의 정의를 만족하지 않는다. 이러한 직선함수를 아핀함수(affine function)라 한다.

### Definition

함수가  $f(x) = a + bx$  의 형태 ( $a, b$  는 상수) 일 때,  $f(x)$  를 아핀함수(affine function) 이라 한다.

### Definition

벡터  $\mathbf{x}$  에 대해 변환

$$\mathbf{y} = A\mathbf{x} + \mathbf{b} \quad (6.29)$$

를 아핀변환(affine transformation)이라고 한다.

**Remark** 아핀변환은 선형변환  $Ax$  을 취한 후, 다시  $\mathbf{b}$  방향으로 평행이동한 변환이다.




Figure 6.6: 아핀변환  $y = Ax + \mathbf{b}$  의 모습

**Remark** 선형변환은  $\mathbf{b} = \mathbf{0}$  인 아핀변환이다.